

ZOIDBERG 2.0

Rapport de projet — Détection automatique de pneumonie par apprentissage automatique

Projet : T-DEV-810 — EPITECH

Version : 2.0.0

Date : Juin 2026

1. Introduction et approche

1.1 Contexte et problématique

La pneumonie est une infection pulmonaire qui constitue l'une des principales causes de mortalité dans le monde, en particulier chez les enfants de moins de cinq ans et les personnes âgées. Son diagnostic repose traditionnellement sur l'interprétation de radiographies thoraciques par un radiologue, une tâche chronophage, subjective et difficile à faire passer à l'échelle dans des environnements médicaux à ressources limitées.

Le projet ZOIDBERG 2.0 vise à concevoir et évaluer un pipeline complet d'intelligence artificielle capable de détecter automatiquement la présence d'une pneumonie à partir d'images de radiographies pulmonaires. L'approche est délibérément progressive : on part des méthodes les plus simples et les plus interprétables, en n'ajoutant de la complexité que là où elle apporte un gain mesurable.

Le pipeline complet est structuré en trois notebooks séquentiels :

Notebook	Étape	Contenu
01	Analyse et vérification de l'intégrité des données	EDA, statistiques descriptives, contrôle qualité
02	Prétraitement et ingénierie des features	Normalisation, PCA, partitionnement train/test
03	Modélisation baseline avec validation croisée	ML classique, split simple, 5-fold CV

1.2 Questions de recherche

Ce rapport est structuré autour de trois questions de recherche dont les réponses sont apportées par les résultats expérimentaux présentés en section 5.

RQ1 — Quelles sont les caractéristiques statistiques et les biais structurels du dataset de radiographies pulmonaires, et comment le déséquilibre de classes influence-t-il le choix des métriques d'évaluation ?

RQ2 — La réduction dimensionnelle par PCA avec conservation de 95 % de la variance est-elle une stratégie viable pour rendre tractable l'entraînement de modèles de ML classiques sur des images 224×224 pixels ?

RQ3 — Les algorithmes de machine learning classiques entraînés sur les features PCA atteignent-ils des performances cliniquement acceptables ($\text{ROC-AUC} \geq 0,85$) pour la détection de pneumonie, et en quoi l'évaluation par cross-validation est-elle plus fiable qu'un simple split train/test ?

1.3 Approche méthodologique

Le choix des métriques est central dans ce projet : en présence d'un déséquilibre de classes (74 % de cas PNEUMONIA), l'accuracy seule est insuffisante — un classifieur naïf qui prédirait toujours "PNEUMONIA" atteindrait 74 % d'accuracy sans aucune capacité discriminante. La **ROC-AUC** est donc choisie comme

métrique primaire, complétée par la précision, le rappel et le F1-score en **averaging macro** pour traiter chaque classe équitablement.

2. Données et analyse exploratoire


2.1 Description des datasets

Le projet s'appuie sur trois datasets distincts, chacun ayant un rôle précis dans le pipeline :

Dataset	Rôle	Total images	NORMAL	PNEUMONIA
Dataset 1	Entraînement principal	5 216	1 341 (25,7 %)	3 875 (74,3 %)
Dataset 2	Validation externe	16	8 (50,0 %)	8 (50,0 %)
Dataset 3	Tuning des hyperparamètres	624	234 (37,5 %)	390 (62,5 %)
Total		5 856	1 583 (27,0 %)	4 273 (73,0 %)

En complément de la classification binaire (NORMAL vs PNEUMONIA), les données permettent une classification multiclass en trois catégories. Dans Dataset 1, la répartition multiclass est la suivante :

Classe	Images	Proportion
BACTERIA	2 530	48,5 %
NORMAL	1 341	25,7 %
VIRUS	1 345	25,8 %




2.2 Caractéristiques techniques des images

L'inspection de l'ensemble du dataset révèle une forte hétérogénéité dimensionnelle, qui justifie le redimensionnement systématique appliqué lors du prétraitement :

Propriété	Valeur
Format	JPEG
Mode colorimétrique	Niveaux de gris (L) majoritairement, quelques RGB
Largeur (min – max)	724 px → 2 144 px
Hauteur (min – max)	286 px → 2 169 px
Intensité pixel — Moyenne	$\sim 124 \pm 18-20$
Intensité pixel — Plage	[0, 255]
Images corrompues	0

L'intégrité complète du dataset (zéro image corrompue sur l'ensemble des fichiers contrôlés) est un prérequis essentiel à la reproductibilité des résultats.



2.3 Déséquilibre de classes et conséquences méthodologiques

Le ratio NORMAL:PNEUMONIA dans Dataset 1 est de **1:2,89**. Ce déséquilibre modéré mais significatif a des conséquences directes sur la modélisation :

L'accuracy paradox. Un classifieur qui prédirait systématiquement "PNEUMONIA" atteindrait une accuracy de 74,3 % — valeur trompeuse qui masque l'absence totale de discriminante. Ce phénomène rend l'accuracy peu fiable comme métrique principale.

Stratégies de compensation adoptées :

- **ROC-AUC** comme métrique primaire (insensible au seuil de décision et au déséquilibre)
- **Averaging macro** pour toutes les métriques agrégées (chaque classe contribue équitablement)
- **Stratification systématique** des splits train/test et des folds de cross-validation (proportions de classes identiques dans chaque partition)

3. Prétraitement et réduction dimensionnelle (PCA)

3.1 Pipeline de prétraitement

Toutes les images des trois datasets subissent le même pipeline de prétraitement avant d'être utilisées par les modèles :

1. **Redimensionnement** → 224 × 224 pixels (format standard compatible avec les CNN modernes)
2. **Conversion en niveaux de gris** (mode L, canal unique)
3. **Normalisation standard** (zero-mean, unit variance, calculée sur l'ensemble du dataset)

Les formes des tenseurs après prétraitement confirment l'application uniforme du pipeline :

Dataset	Forme du tenseur	Plage de valeurs normalisées
Dataset 1	(5 216, 224, 224, 1)	[−6,85 ; 6,15]
Dataset 2	(16, 224, 224, 1)	[−2,60 ; 3,02]
Dataset 3	(624, 224, 224, 1)	[−3,53 ; 5,19]

3.2 Partitionnement train/test

Le partitionnement est réalisé sur l'ensemble combiné (Dataset 1 + Dataset 2), avec une stratégie **80/20 stratifiée** (random_state=42) pour garantir la reproductibilité et le maintien des proportions de classes :

Partition	Total	NORMAL	BACTERIA	VIRUS
Train	4 185	1 079	2 030	1 076
Test	1 047	270	508	269

Le test set n'est utilisé qu'une seule fois, à la fin de l'évaluation, pour éviter tout biais d'optimisation.


3.3 Réduction dimensionnelle par PCA

La PCA (Analyse en Composantes Principales) est appliquée **avant tous les modèles de machine learning classique** pour rendre leur entraînement computationnellement faisable. Le problème de dimensionnalité est le suivant : une image 224×224 aplatie produit un vecteur de **50 176 features**. À cette dimension, certains algorithmes (SVM à noyau RBF, régression logistique régularisée) deviennent prohibitifs en mémoire et en temps de calcul. La justification computationnelle complète est disponible en Annexe D.

Résultats de la PCA :

Paramètre	Valeur
Critère de sélection	Conservation de 95 % de la variance
Nombre de composantes retenues	792
Variance totale expliquée	95,01 %
Réduction dimensionnelle	98,4 % (50 176 → 792 features)
Whitening	Activé

En conservant 792 composantes sur 50 176, la PCA élimine 98,4 % des dimensions tout en préservant 95,01 % de l'information discriminante. La variance restante (4,99 %) correspond principalement au bruit de fond et aux artefacts d'acquisition sans valeur prédictive.



4. Modèles baseline — Machine Learning classique

4.1 Modèles évalués

Quatre algorithmes de machine learning classique sont entraînés sur les 792 features PCA :

- **Logistic Regression (LR)** — modèle linéaire de référence, rapide et interprétable
- **SVM à noyau RBF (SVM)** — séparateur à marge maximale, efficace en haute dimension grâce au noyau
- **Random Forest (RF)** — ensemble d'arbres de décision par bagging, robuste au bruit
- **Gradient Boosting (GB)** — boosting séquentiel, optimisation itérative de l'erreur résiduelle

Tous les modèles sont évalués selon deux protocoles complémentaires dont la comparaison est discutée en Annexe B :

- **Split simple 80/20** — évaluation rapide, dépend du tirage aléatoire
- **Cross-validation 5-fold stratifiée** — évaluation robuste avec intervalle de confiance

4.2 Résultats — Split simple (train 80 % / test 20 %)

Modèle	ROC-AUC	Accuracy	Precision	Recall	F1-Score	Temps (s)
Logistic Regression	0,8628	0,7163	0,7106	0,7225	0,7146	0,50
SVM (RBF)	0,8895	0,7584	0,7545	0,7455	0,7493	60,93
Random Forest	0,8470	0,6227	0,7543	0,5176	0,5166	1,14
Gradient Boosting	0,8931	0,7584	0,7519	0,7204	0,7246	175,40

En split simple, le Gradient Boosting obtient le ROC-AUC le plus élevé (0,8931), suivi de très près par le SVM (0,8895). Le Random Forest se démarque négativement : malgré une précision correcte (0,7543), son recall chute à 0,5176, révélant une difficulté systématique à détecter la classe VIRUS — la moins représentée dans le jeu de données.

4.3 Résultats — Cross-validation 5-fold stratifiée

Les paramètres détaillés de la cross-validation sont disponibles en Annexe C. Les résultats sont exprimés en **moyenne ± écart-type** sur les 5 folds :

Modèle	ROC-AUC	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0,8569 ± 0,0069	0,6999 ± 0,0067	0,7011 ± 0,0097	0,7090 ± 0,0085	0,7024 ± 0,0084
SVM (RBF)	0,8943 ± 0,0063	0,7626 ± 0,0128	0,7642 ± 0,0113	0,7546 ± 0,0108	0,7590 ± 0,0108
Random Forest	0,8428 ± 0,0076	0,6353 ± 0,0095	0,7654 ± 0,0179	0,5368 ± 0,0116	0,5458 ± 0,0151

Modèle	ROC-AUC	Accuracy	Precision	Recall	F1-Score
Gradient Boosting	0,8876 ± 0,0062	0,7619 ± 0,0045	0,7560 ± 0,0057	0,7306 ± 0,0080	0,7350 ± 0,0071

En cross-validation, le **SVM (RBF)** s'impose comme le meilleur modèle avec un ROC-AUC de **0,8943 ± 0,0063**. L'écart-type faible (0,0063) indique une excellente stabilité entre les folds : les performances ne dépendent pas du tirage aléatoire. À l'inverse, le Gradient Boosting, qui semblait légèrement supérieur en split simple (0,8931), descend à 0,8876 en CV — signe que son résultat en split simple était très légèrement optimiste.

4.4 Analyse de cohérence entre les deux protocoles

La cohérence entre split simple et cross-validation est un indicateur de robustesse des résultats. Un écart important trahirait un overfitting sur le split ou une forte sensibilité au tirage aléatoire.

Modèle	ROC-AUC (split)	ROC-AUC (CV 5-fold)	Δ	Interprétation
Gradient Boosting	0,8931	0,8876 ± 0,0062	-0,006	Cohérent — split très légèrement optimiste
SVM (RBF)	0,8895	0,8943 ± 0,0063	+0,005	Cohérent — CV confirme la robustesse
Logistic Regression	0,8628	0,8569 ± 0,0069	-0,006	Cohérent
Random Forest	0,8470	0,8428 ± 0,0076	-0,004	Cohérent

Tous les écarts restent inférieurs à **1 point de ROC-AUC** ($|\Delta| < 0,01$). Cette cohérence systématique confirme que les résultats sont robustes et ne résultent pas d'un tirage aléatoire favorable. Le classement des modèles est stable entre les deux protocoles, ce qui renforce la confiance dans les conclusions.



4.5 Analyse par modèle


Logistic Regression. Performance homogène mais limitée (ROC-AUC 0,857 en CV). La frontière de décision linéaire est insuffisante pour capturer la complexité des patterns visuels dans l'espace PCA à 792 dimensions. C'est le modèle de référence inférieure.

SVM (RBF). Meilleur modèle en CV (ROC-AUC 0,8943). Le noyau RBF permet de capturer des non-linéarités dans l'espace PCA, ce qui explique sa supériorité sur la régression logistique. Coût : 343,56 s de cross-validation, soit le temps le plus long.

Random Forest. ROC-AUC correct (0,843) mais recall catastrophique (0,537 en CV). Le bagging d'arbres surpondère la classe majoritaire (BACTERIA), au détriment de la classe VIRUS. Ce problème persiste malgré la stratification, ce qui suggère que les arbres de décision ne sont pas adaptés à ce type d'espace de features dense (792 dimensions PCA).

Gradient Boosting. Résultats proches du SVM (ROC-AUC 0,888 en CV), avec un meilleur recall que Random Forest (0,731). Temps d'entraînement le plus long (227,73 s en CV), pour des performances légèrement inférieures au SVM.





5. Synthèse et réponses aux questions de recherche

5.1 Tableau récapitulatif

Modèle	ROC-AUC (split)	ROC-AUC (CV)	F1 (CV)	Temps CV (s)	Verdict
SVM (RBF)	0,8895	0,8943 ± 0,006	0,7590	343,56	✓ Meilleur modèle
Gradient Boosting	0,8931	0,8876 ± 0,006	0,7350	227,73	✓ Bon compromis
Logistic Regression	0,8628	0,8569 ± 0,007	0,7024	29,52	⚠ Limite inférieure

Modèle	ROC-AUC (split)	ROC-AUC (CV)	F1 (CV)	Temps CV (s)	Verdict
Random Forest	0,8470	0,8428 ± 0,008	0,5458	8,01	 Recall insuffisant

5.2 Réponse à RQ1

RQ1 : Quelles sont les caractéristiques et les biais du dataset, et comment le déséquilibre influence-t-il le choix des métriques ?

Le dataset présente un déséquilibre modéré mais structurel : le ratio NORMAL:PNEUMONIA est de 1:2,89 dans Dataset 1 (74,3 % de cas positifs). Ce biais rend l'accuracy inadaptée comme métrique principale — un classifieur trivial atteindrait 74 % sans aucune discrimination. La réponse méthodologique est le choix du **ROC-AUC comme métrique primaire** (indépendante du seuil et du déséquilibre) et de l'**averaging macro** pour les métriques agrégées. La stratification systématique des splits garantit que ce déséquilibre est représenté uniformément dans toutes les partitions.

5.3 Réponse à RQ2

RQ2 : La PCA à 95 % de variance est-elle une stratégie viable pour rendre tractable le ML classique sur des images 224×224 ?

Oui, et de manière très efficace. La PCA réduit la dimensionnalité de 50 176 à 792 features (−98,4 %) tout en conservant 95,01 % de la variance. Cette compression rend l'entraînement du SVM (noyau RBF) faisable en 60,93 s (split) et 343,56 s (CV), contre une durée théoriquement prohibitive sans PCA (la matrice de Gram serait de l'ordre du téraoctet — cf. Annexe D). La qualité des features PCA est validée par les performances obtenues : tous les modèles dépassent ROC-AUC = 0,84.

5.4 Réponse à RQ3

RQ3 : Les modèles ML classiques sur PCA atteignent-ils ROC-AUC ≥ 0,85, et la CV est-elle plus fiable qu'un split simple ?

Oui pour les deux volets. Trois des quatre modèles testés (SVM, GB, LR) dépassent le seuil de 0,85 en cross-validation :

- SVM (RBF) : **0,8943** 
- Gradient Boosting : **0,8876** 
- Logistic Regression : **0,8569** 
- Random Forest : 0,8428  (recall VIRUS insuffisant)

Sur la fiabilité de la CV : les écarts entre split simple et CV restent tous inférieurs à 0,007 point de ROC-AUC, ce qui confirme que les deux protocoles convergent. Cependant, la CV fournit en plus un

intervalle de confiance ($\pm 0,006$ à $\pm 0,008$) qui quantifie la stabilité du modèle — information impossible à obtenir avec un seul split.

Annexe A — Définition et interprétation des métriques

Les métriques utilisées dans ce rapport sont définies ci-dessous en termes de vrais positifs (TP), faux positifs (FP), vrais négatifs (TN) et faux négatifs (FN). Dans le contexte de la détection de pneumonie, la **classe positive est PNEUMONIA**.

Métrique	Formule	Interprétation médicale
Accuracy	$(TP + TN) / (TP + TN + FP + FN)$	Taux global de prédictions correctes. Trompeuse si classes déséquilibrées (<i>accuracy paradox</i>).
Precision	$TP / (TP + FP)$	Parmi tous les cas diagnostiqués "pneumonie" par le modèle, quelle proportion l'était vraiment ? Mesure le taux de fausses alarmes.
Recall (Sensibilité)	$TP / (TP + FN)$	Parmi tous les vrais cas de pneumonie présents, quelle proportion a été détectée ? Métrique critique en médecine : manquer un cas est plus grave que sur-diagnostiquer.
Spécificité	$TN / (TN + FP)$	Parmi tous les cas réellement normaux, quelle proportion a été correctement classée ? Capacité à ne pas sur-diagnostiquer.
F1-Score	$2 \times (P \times R) / (P + R)$	Moyenne harmonique de la précision et du rappel. Bon compromis lorsque les deux types d'erreurs ont un coût.
ROC-AUC	Aire sous la courbe ROC ($x = FPR, y = TPR$)	Capacité de discrimination du modèle, indépendante du seuil de décision . 0,5 = aléatoire, 1,0 = parfait. Robuste au déséquilibre.

Lecture de la courbe ROC. La courbe ROC trace le taux de vrais positifs (TPR = Recall) en fonction du taux de faux positifs (FPR = 1 – Spécificité) pour tous les seuils de décision possibles. Un modèle parfait aurait une courbe qui passe par le coin supérieur gauche (TPR=1, FPR=0). L'AUC (aire sous cette courbe) synthétise cette performance en un seul scalaire.

Averaging macro. Pour les problèmes multiclassés (NORMAL / BACTERIA / VIRUS), chaque métrique est calculée indépendamment pour chaque classe, puis la moyenne non pondérée est prise. Cette approche traite chaque classe à égalité, sans avantager la classe majoritaire.

L'accuracy paradox en chiffres. Sur Dataset 1 (74,3 % de PNEUMONIA) : un classifieur trivial qui prédirait toujours "PNEUMONIA" atteindrait 74,3 % d'accuracy, 0 % de recall sur NORMAL, et un ROC-AUC de 0,50. Le Random Forest de ce projet, avec 62,3 % d'accuracy en split simple, est donc en réalité *meilleur* que ce classifieur naïf sur les métriques qui comptent.

Annexe B — Comparaison avec et sans cross-validation

Pourquoi utiliser deux protocoles d'évaluation ?

Le **split simple** (80/20) est rapide et intuitif, mais ses résultats dépendent du tirage aléatoire. Avec 1 047 images dans le test set, la variance d'échantillonnage est non négligeable : un split "chanceux" peut sur-estimer les performances de plusieurs points de pourcentage.

La **cross-validation k-fold stratifiée** ($k = 5$) résout ce problème en utilisant l'intégralité des données pour la validation : chaque image appartient exactement une fois au fold de test. La moyenne et l'écart-type sur les 5 folds donnent :

1. Une **estimation non biaisée** de la performance réelle
2. Un **intervalle de confiance** qui quantifie la stabilité du modèle

Tableau comparatif

Modèle	ROC-AUC (split)	ROC-AUC (CV 5-fold)	$ \Delta $	Conclusion
Gradient Boosting	0,8931	0,8876 $\pm$ 0,0062	0,006	Split légèrement optimiste
SVM (RBF)	0,8895	0,8943 $\pm$ 0,0063	0,005	Split légèrement pessimiste
Logistic Regression	0,8628	0,8569 $\pm$ 0,0069	0,006	Cohérent
Random Forest	0,8470	0,8428 $\pm$ 0,0076	0,004	Cohérent

Les quatre modèles présentent des écarts inférieurs à **0,007 point de ROC-AUC** entre les deux protocoles. Cette cohérence valide rétrospectivement la qualité du split 80/20 : le tirage aléatoire n'a pas introduit de biais significatif dans ce cas. Néanmoins, la CV reste **préférable pour les résultats définitifs** car elle fournit les écarts-types qui permettent de tester la significativité statistique des différences de performance entre modèles.

Quand préférer l'un ou l'autre ?

Critère	Split simple	Cross-validation 5-fold
Vitesse d'itération	✓ Rapide ($\times 1$)	✗ Lent ($\times 5$)
Estimation non biaisée	⚠ Dépend du tirage	✓ Robuste
Intervalle de confiance	✗ Impossible	✓ $\pm$ std disponible
Utilisation de toutes les données	✗ 80 % seulement	✓ 100 %
Résultats à publier / reporter	⚠ Acceptable si cohérent avec CV	✓ Recommandé

Annexe C — Paramètres complets de la cross-validation et du Grid Search

Cross-validation principale (évaluation des modèles — Notebook 03)

```

Méthode      : StratifiedKfold
k            : 5 folds
Stratification : Oui — proportions de classes identiques dans chaque fold
Variation max. :  $\pm 1$  sample entre folds (vérifiée)
random_state  : 42
Averaging     : Macro (chaque classe contribue équitablement)
Scoring       : ROC-AUC (One-vs-Rest, macro-average)
  
```

Distribution des classes par fold (approximative, stratification assure ± 1 sample) :

Fold	NORMAL	BACTERIA	VIRUS	Total
1	~216	~406	~215	837
2	~216	~406	~215	837
3	~216	~406	~215	837
4	~216	~406	~215	837
5	~215	~406	~216	837

Chaque fold utilise $4 \times 837 = 3\,348$ images pour l'entraînement et 837 images pour la validation.

Cross-validation pour le Grid Search (hyperparameter tuning — prévu)

```
Méthode      : GridSearchCV (sklearn)
CV folds     : 3
Dataset      : Dataset 3 (624 images, dédié exclusivement au tuning)
Scoring      : roc_auc
Parallélisation : n_jobs=-1 (tous les cœurs disponibles)
```

Dataset 3 est réservé exclusivement au tuning pour éviter toute contamination des estimations de performance par les hyperparamètres optimisés (*data leakage* entre tuning et évaluation).

Paramètres de configuration générale (config.yaml)

```
random_state : 42
cv_folds     : 5
test_size    : 0.2
stratify     : true
image_size   : [224, 224]
color_mode   : grayscale
normalization : standard
pca_variance : 0.95
pca_whiten   : true
```

Annexe D — Détails techniques de la PCA

Paramètres sklearn

```
from sklearn.decomposition import PCA

pca = PCA(n_components=0.95, whiten=True, random_state=42)
X_train_pca = pca.fit_transform(X_train_flat)
# Entrée : (4185, 50176) – images 224×224 aplaties
# Sortie : (4185, 792) – composantes principales

X_test_pca = pca.transform(X_test_flat)
```

```
# Entrée : (1047, 50176)
# Sortie : (1047, 792)
```

Paramètre	Valeur	Signification
n_components	0.95	Sélection automatique du nombre de composantes par variance cible
Composantes retenues	792	Nombre effectif de dimensions après réduction
Variance expliquée	95,01 %	Part de l'information totale conservée
Réduction	98,4 %	50 176 → 792 features
whiten	True	Normalise la variance de chaque composante à 1

Justification computationnelle

Sans PCA, l'entraînement du SVM à noyau RBF sur les features brutes serait impossible :

Métrique	Sans PCA (d = 50 176)	Avec PCA (d' = 792)	Gain
Taille de la matrice de Gram	$(4\,185)^2 \times 50\,176 \approx \mathbf{3,5\ To}$	$(4\,185)^2 \times 792 \approx \mathbf{55\ Go}$	×64
Complexité calcul kernel	$O(n^2 \times d)$	$O(n^2 \times d')$	×63
Temps entraînement SVM	Prohibitif	60,93 s	—

La PCA ramène le problème dans un régime computationnellement faisable, sans perte significative de performance discriminante (95,01 % de variance conservée).

Le rôle du whitening

Le whitening (whiten=True) normalise la variance de chaque composante principale à 1 après la projection. Sans whitening, les premières composantes (qui capturent la variance globale) ont une échelle beaucoup plus grande que les dernières. Cette disproportion biaise les modèles sensibles à l'échelle des features :

- **SVM (noyau RBF)** : la distance euclidienne utilisée dans le noyau est faussée si les échelles diffèrent
- **Logistic Regression** : la régularisation L2 pénalise uniformément tous les coefficients, ce qui suppose des features à échelle comparable

Interprétation des composantes principales

Les premières composantes principales capturent les variations **globales** : gradients d'intensité sur l'ensemble du champ pulmonaire, différences de densité moyenne entre classes. Les composantes d'ordre supérieur encodent des structures de plus en plus locales — contours, opacités focales, consolidations — qui peuvent être discriminantes pour distinguer BACTERIA (opacités denses et localisées) de VIRUS (infiltrats diffus). Le graphique de variance cumulée montre que le coude de la

courbe se situe précisément autour de la 792ème composante, confirmant que le seuil de 95 % est un choix optimal.

Rapport ZOIDBERG 2.0 — Périmètre Notebooks 01-03 — T-DEV-810-PAR_19, EPITECH, Juin 2026.